Formelsammlung – Angewandte Statistik

- **Geltungsbereich:** Pflichtkern des 48-UE-Moduls für BWL, Management, Wirtschaftsinformatik und Informatik
- **Arbeitsmittel in der Klausur:** diese Formelsammlung und ein nicht programmierbarer Taschenrechner
- **Analysesoftware in Lehrveranstaltung und Fallstudie:** JASP

0. So wird die Formelsammlung benutzt

Zu jedem Formelblock stehen:

- **Größen:** Bedeutung der Zeichen,
- **Voraussetzungen:** wann die Formel passt,
- **Einheit:** Einheit des Ergebnisses,
- **Warnung:** häufigster Anwendungs- oder Interpretationsfehler.

Alle benötigten kritischen z- und t-Werte werden in der jeweiligen Aufgabe angegeben. Zur Orientierung:

Zweiseitiges Konfidenzniveau	$z_{1-\alpha/2}$
$90\,\%$	$1{,}645$
$95\,\%$	$1{,}960$
$99\,\%$	$2{,}576$

Für t-Werte müssen zusätzlich die Freiheitsgrade bekannt sein. Es ist keine Tabelle auswendig zu lernen.

Notation und Rundung

- n: Zahl der tatsächlich ausgewerteten Beobachtungen; bei gepaarten Analysen Zahl der **vollständigen Paare**.
- x_i, y_i: beobachtete Werte; $\bar{x}, \bar{y}$: Stichprobenmittelwerte.
- μ, σ: Mittelwert und Standardabweichung einer Grundgesamtheit bzw. eines ausdrücklich vorgegebenen Modells.
- s: mit $n-1$ geschätzte Stichprobenstandardabweichung.
- $\hat{p}$: beobachteter Stichprobenanteil.
- Zwischenwerte ungerundet weiterverwenden. Endergebnisse, sofern nicht anders verlangt: Anteile auf drei Dezimalen, Prozente auf eine Dezimalstelle, Messwerte auf zwei Dezimalstellen, t, r und Regressionswerte auf drei Dezimalen. Ein p-Wert unter $0{,}001$ wird als $p < 0{,}001$ berichtet.
- Jede Zahl erhält ihren Nenner, ihre Einheit und – bei gerundeten Ergebnissen – ein Näherungszeichen.

---

1. Häufigkeiten, Lage und Streuung

1.1 Absolute und relative Häufigkeit

$$h_i = \frac{n_i}{n}, \qquad h_i(\%) = 100 \cdot h_i$$

- **Größen:** n_i = Zahl der Beobachtungen in Kategorie i; n = Bezugsgröße; h_i = relativer Anteil.
- **Voraussetzungen:** Zähler und Nenner beziehen sich auf dieselbe Beobachtungseinheit und Auswahl.
- **Einheit:** h_i ist einheitenlos; $h_i(\%)$ wird in Prozent angegeben.

- **Warnung:** Bei Multiple Choice können Personen mehrere Optionen nennen; Optionsanteile müssen dann nicht 100 % ergeben. Immer den tatsächlichen Nenner nennen.

1.2 Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

- **Größen:** x_i = metrischer Einzelwert; n = Zahl gültiger Werte; $\sum$ = alle angegebenen Werte addieren.
- **Voraussetzungen:** metrische Werte; der Mittelwert ist für die Fragestellung inhaltlich sinnvoll.
- **Einheit:** dieselbe Einheit wie x.
- **Warnung:** Ausreißer und Schiefe können $\bar{x}$ stark beeinflussen. Fehlende Werte werden nicht als null eingesetzt.

1.3 Median und Modalwert

Für sortierte Werte $x_{(1)} \le \dots \le x_{(n)}$:

$$\tilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)}, & n \text{ ungerade}, \\ \dfrac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}, & n \text{ gerade}. \end{cases}$$

Der Modalwert ist die am häufigsten beobachtete Ausprägung.

- **Größen:** $x_{(j)}$ = Wert an sortierter Position j; $\tilde{x} = Q_2$ = Median.
- **Voraussetzungen:** Median mindestens ordinales Skalenniveau; Mittelung der beiden mittleren Werte nur bei metrischen Werten. Modalwert ab nominalem Skalenniveau.
- **Einheit:** Median und Modalwert haben die Einheit bzw. Kategorie von x.
- **Warnung:** Vor der Medianbestimmung sortieren. Es kann keinen, einen oder mehrere Modalwerte geben.

1.4 Spannweite

$$R = x_{\max} - x_{\min}$$

- **Größen:** $x_{\max}$ = größter, $x_{\min}$ = kleinster gültiger Wert.
- **Voraussetzungen:** metrische Daten.
- **Einheit:** dieselbe Einheit wie x.
- **Warnung:** R verwendet nur zwei Werte und reagiert sehr stark auf Ausreißer.

1.5 Quartile und Interquartilsabstand

$$IQR = Q_3 - Q_1$$

- **Größen:** Q_1 = 25 %-Quantil; Q_3 = 75 %-Quantil; IQR = Breite der mittleren 50 %.
- **Voraussetzungen:** mindestens ordinale Daten; die Quartilskonvention stammt aus der Aufgabe oder aus der benannten JASP-Ausgabe.
- **Einheit:** dieselbe Einheit wie x.
- **Warnung:** Es existieren mehrere korrekte Quartilskonventionen. Nicht unbemerkt Werte aus verschiedenen Konventionen mischen.

Explorative Boxplot-Grenzen:

$$G_{\text{unten}} = Q_1 - 1{,}5 \cdot IQR, \qquad G_{\text{oben}} = Q_3 + 1{,}5 \cdot IQR$$

- **Größen:** $G_{\text{unten}}, G_{\text{oben}}$ = rechnerische Prüfgrenzen.
- **Voraussetzungen:** Quartile und IQR wurden mit derselben Konvention bestimmt.
- **Einheit:** dieselbe Einheit wie x.
- **Warnung:** Ein Wert außerhalb der Grenzen ist ein Prüfsignal, kein automatischer Löschgrund.

1.6 Deskriptive Varianz und Standardabweichung: Division durch n

$$s^2_{\text{des}} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s_{\text{des}} = \sqrt{s^2_{\text{des}}}$$

- **Größen:** s^2_{des} = Varianz der vollständig beschriebenen vorliegenden Werte; s_{des} = zugehörige Standardabweichung.
- **Voraussetzungen:** metrische Daten; Ziel ist die reine Beschreibung genau dieser beobachteten Wertemenge.
- **Einheit:** Varianz in $(\text{Einheit von } x)^2$; Standardabweichung in der Einheit von x.
- **Warnung:** Dieser Nenner ist nicht der übliche unverzerrte Schätzer für eine unbekannte Populationsvarianz. Die ARSnova-Zusammenfassung numerischer Schätzungen verwendet für die deskriptive Varianz n.

1.7 Stichprobenvarianz und -standardabweichung: Division durch $n - 1$

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2, \qquad s = \sqrt{s^2}$$

- **Größen:** s^2 = Stichprobenschätzer der Varianz; s = geschätzte Standardabweichung; $n - 1$ = Freiheitsgrade.
- **Voraussetzungen:** metrische Daten, $n > 1$; die vorliegenden Werte werden als Stichprobe für eine größere Population bzw. für Inferenz behandelt.
- **Einheit:** s^2 in $(\text{Einheit von } x)^2$; s in der Einheit von x.
- **Warnung:** Nicht mit s_{des} verwechseln. Für Standardfehler, Mittelwertintervalle und t-Tests wird in diesem Modul s mit $n - 1$ verwendet.

Für dieselben ungerundeten Werte gilt:

$$s^2 = s^2_{\text{des}}\frac{n}{n-1}, \qquad s = s_{\text{des}}\sqrt{\frac{n}{n-1}}$$

- **Größen:** wie oben.
- **Voraussetzungen:** Beide Kennzahlen beruhen auf exakt denselben gültigen Einzelwerten und demselben Mittelwert; $n > 1$.
- **Einheit:** links und rechts jeweils dieselbe Varianz- bzw. Maßeinheit.
- **Warnung:** Bereits gerundete Softwarewerte erzeugen kleine Rundungsabweichungen.

---

2. Wahrscheinlichkeit und Verteilungen

Für jedes Ereignis A gilt $0 \le P(A) \le 1$.

2.1 Additionsregel

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- **Größen:** $A \cup B$ = „A oder B oder beide“; $A \cap B$ = „A und B“.

- **Voraussetzungen:** A und B gehören zum selben Zufallsexperiment.
- **Einheit:** einheitenlose Wahrscheinlichkeit bzw. Prozent.
- **Warnung:** Die Überschneidung wird sonst doppelt gezählt.

Für disjunkte Ereignisse mit $A \cap B = \varnothing$:

$$P(A \cup B) = P(A) + P(B)$$

- **Größen:** wie oben.
- **Voraussetzungen:** A und B können nicht gleichzeitig eintreten.
- **Einheit:** einheitenlos.
- **Warnung:** „Disjunkt“ ist nicht dasselbe wie „unabhängig“.

2.2 Gegenereignis

$$P(\overline{A}) = 1 - P(A)$$

- **Größen:** $\overline{A}$ = „A tritt nicht ein“.
- **Voraussetzungen:** A und $\overline{A}$ decken alle möglichen Ergebnisse ab.
- **Einheit:** einheitenlos.
- **Warnung:** Das Gegenereignis muss vollständig formuliert sein; zu „mindestens eins“ gehört „kein einziges“.

2.3 Bedingte Wahrscheinlichkeit

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \qquad \text{für } P(B) > 0$$

- **Größen:** $P(A \mid B)$ = Wahrscheinlichkeit von A innerhalb der Bezugsgruppe B.
- **Voraussetzungen:** $P(B) > 0$; Zähler und Nenner beziehen sich auf dieselbe bedingte Bezugsgruppe.
- **Einheit:** einheitenlos.
- **Warnung:** Im Allgemeinen gilt $P(A \mid B) \neq P(B \mid A)$. Der Nenner steht rechts vom Strich.

2.4 Multiplikationsregel und Unabhängigkeit

$$P(A \cap B) = P(A \mid B) \cdot P(B)$$

- **Größen:** wie in Abschnitt 2.3.
- **Voraussetzungen:** $P(B) > 0$.
- **Einheit:** einheitenlos.
- **Warnung:** $P(A \mid B)$ darf nur bei nachgewiesener oder modellhaft gesetzter Unabhängigkeit durch $P(A)$ ersetzt werden.

Bei unabhängigen Ereignissen:

$$P(A \cap B) = P(A) \cdot P(B)$$

- **Größen:** A, B = unabhängige Ereignisse.
- **Voraussetzungen:** Das Eintreten des einen Ereignisses verändert die Wahrscheinlichkeit des anderen nicht.
- **Einheit:** einheitenlos.
- **Warnung:** Gleiche Randwahrscheinlichkeiten beweisen keine Unabhängigkeit.

2.5 Satz der totalen Wahrscheinlichkeit und Bayes

Für die Aufteilung $A, \overline{A}$:

$$P(B) = P(B \mid A)P(A) + P(B \mid \overline{A})P(\overline{A})$$

- **Größen:** Die beiden Summanden sind die disjunkten Wege zu B.
- **Voraussetzungen:** A und $\overline{A}$ bilden eine vollständige Aufteilung; die verwendeten Bedingungen sind definiert.
- **Einheit:** einheitenlos.
- **Warnung:** Basisraten $P(A)$ und $P(\overline{A})$ nicht weglassen.

Bayes-Regel:

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)} = \frac{P(B \mid A)P(A)}{P(B \mid A)P(A) + P(B \mid \overline{A})P(\overline{A})}$$

- **Größen:** $P(A)$ = Basisrate; $P(B \mid A)$ = Wahrscheinlichkeit von B, wenn A vorliegt; $P(A \mid B)$ = gesuchte umgekehrte Bedingung.
- **Voraussetzungen:** $P(B) > 0$; die Aufteilung und Wahrscheinlichkeiten beziehen sich auf dieselbe Population.
- **Einheit:** einheitenlos.
- **Warnung:** Eine hohe bedingte Wahrscheinlichkeit $P(B \mid A)$ garantiert bei seltener Basisrate keine hohe $P(A \mid B)$. Eine Vierfeldertafel mit absoluten Häufigkeiten ist oft der sicherste Rechenweg.

2.6 Binomialverteilung

Binomialkoeffizient:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

- **Größen:** n = feste Versuchszahl; k = Zahl der Erfolge, $k \in \{0, \dots, n\}$.
- **Voraussetzungen:** n, k sind nichtnegative ganze Zahlen und $k \leq n$.
- **Einheit:** einheitenlose Anzahl möglicher Anordnungen.
- **Warnung:** $0! = 1$. Der Binomialkoeffizient allein ist noch keine Wahrscheinlichkeit.

Für $X \sim Bin(n, p)$:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

- **Größen:** X = Anzahl der Erfolge; p = konstante Erfolgswahrscheinlichkeit je Versuch.
- **Voraussetzungen:** feste Zahl n, genau zwei Ausgänge je Versuch, konstantes p, unabhängige Versuche.
- **Einheit:** einheitenlose Wahrscheinlichkeit.
- **Warnung:** Unterschiedlich schwierige MC-Aufgaben oder wiederholte Antworten derselben Person können konstantes p bzw. Unabhängigkeit verletzen.

Erwartungswert und Standardabweichung:

$$E(X) = np, \qquad \sigma_X = \sqrt{np(1-p)}$$

- **Größen:** $E(X)$ = langfristig erwartete Erfolgszahl; σ_X = Streuung der Erfolgszahl.
- **Voraussetzungen:** dasselbe Binomialmodell wie oben.
- **Einheit:** Anzahl Erfolge.
- **Warnung:** $E(X)$ muss keine mögliche ganze Beobachtung sein.

Mindestens ein Erfolg:

$$P(X \geq 1) = 1 - P(X = 0) = 1 - (1-p)^n$$

- **Größen:** wie oben.
- **Voraussetzungen:** dasselbe Binomialmodell wie oben.
- **Einheit:** einheitenlose Wahrscheinlichkeit.
- **Warnung:** Das Gegenereignis zu „mindestens ein Erfolg“ ist „kein Erfolg“, nicht „genau ein Misserfolg“.

2.7 Standardisierung

$$z = \frac{x - \mu}{\sigma}$$

- **Größen:** x = Beobachtung; μ, σ = Mittelwert und positive Standardabweichung der angegebenen Referenzverteilung.
- **Voraussetzungen:** metrische Daten; $\sigma > 0$. Wahrscheinlichkeiten aus z nur dann ableiten, wenn das Verteilungsmodell dies erlaubt.
- **Einheit:** z ist einheitenlos.
- **Warnung:** Standardisieren macht eine schiefe Verteilung nicht normal.

---

3. Standardfehler, Konfidenzintervalle und Testen

Ein Standardfehler beschreibt die modellbedingte Streuung eines **Stichprobenschätzers**, nicht die Streuung der Einzelwerte.

3.0 Verbindliche Verfahrensmatrix des Pflichtkerns

Untersuchungsfrage und Design	Verfahren im Pflichtkern	Nicht verlangt
unbekannter Anteil aus unabhängigen Fällen	Punktschätzung $\hat{p}$ und Anteils-Konfidenzintervall	Anteils- oder Binomialtest
unbekannter Mittelwert aus unabhängigen metrischen Fällen	Punktschätzung $\bar{x}$ und t-Konfidenzintervall	Ein-Stichproben- oder unabhängiger Mittelwerttest
mittlere Veränderung vollständig gepaarter metrischer Werte	Konfidenzintervall der Differenzen und gepaarter t-Test	Test aus bloßen Rundenaggregaten oder unabhängiger Gruppenvergleich

Die Verfahrenswahl folgt der Untersuchungsfrage, dem Skalenniveau und dem Design. Ein Konfidenzintervall ist kein Hypothesentest. Als Hypothesentest wird im Pflichtkern ausschließlich der gepaarte t-Test berechnet und aus JASP gelesen.

3.1 Geschätzter Standardfehler des Mittelwerts

$$SE(\bar{x}) = \frac{s}{\sqrt{n}}$$

- **Größen:** s = Stichprobenstandardabweichung mit $n - 1$; n = Zahl unabhängiger gültiger Beobachtungen.
- **Voraussetzungen:** metrische Daten; Beobachtungen im verwendeten Stichprobenmodell unabhängig.
- **Einheit:** dieselbe Einheit wie x.
- **Warnung:** Nicht s_{des} aus einer durch n geteilten ARSnova-Anzeige ungeprüft einsetzen. Größeres n verringert den Standardfehler, beseitigt aber keine Auswahlverzerrung.

3.2 Geschätzter Standardfehler eines Anteils

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

- **Größen:** $\hat{p} = x/n$ = beobachteter Anteil; x = Erfolgszahl.
- **Voraussetzungen:** binäres Merkmal und modellhaft unabhängige Beobachtungen.
- **Einheit:** einheitenloser Anteil.
- **Warnung:** Der Standardfehler ist keine Fehlerrate und kein Konfidenzintervall.

3.3 Wald-Konfidenzintervall für einen Anteil

$$KI_{\text{Wald}} = \hat{p} \pm z_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

- **Größen:** α = Irrtumsniveau; $z_{1-\alpha/2}$ = in der Aufgabe angegebener kritischer Wert.
- **Voraussetzungen:** binäre, modellhaft unabhängige Beobachtungen; Lehrregel für die Näherung: $n\hat{p} \geq 10$ und $n(1-\hat{p}) \geq 10$.
- **Einheit:** einheitenloser Anteil bzw. nach Multiplikation mit 100 Prozent.
- **Warnung: Wald** ausdrücklich benennen. Bei kleinem n oder Anteilen nahe 0 bzw. 1 kann es unzuverlässig sein und sogar Grenzen außerhalb $[0;1]$ liefern. Dann nicht willkürlich abschneiden, sondern ein bereitgestelltes Wilson-Intervall lesen.

3.4 Wilson-Konfidenzintervall – ausdrücklich nur als Leseintervall

In Aufgaben erscheint beispielsweise:

$$95\,\%\text{-Wilson-KI für } p = [L_W; U_W]$$

- **Größen:** L_W = Wilson-Untergrenze; U_W = Wilson-Obergrenze; $\hat{p} = x/n$ bleibt der beobachtete Punktwert.
- **Voraussetzungen:** Die Ausgabe bezeichnet das Intervall ausdrücklich als **Wilson-Konfidenzintervall** und nennt Zähler, Nenner und Konfidenzniveau.
- **Einheit:** einheitenloser Anteil bzw. Prozent.
- **Warnung:** In diesem Modul wird Wilson **abgelesen, nicht mit der Wald-Formel nachgerechnet**. Eine einzelne Wilson-Untergrenze aus einem Ranking ist weder $\hat{p}$ noch ein vollständiges Intervall. Ein Intervall korrigiert keine Selbstselektion.

Sichere Interpretation eines 95 %-Intervalls:

> Das Verfahren erzeugt bei sehr vielen gleichartigen Stichproben in ungefähr 95 % der Fälle Intervalle, die den festen Populationsparameter enthalten. Für die vorliegenden Daten reichen die mit dem Modell vereinbaren Parameterwerte von der Unter- bis zur Obergrenze.

Nicht korrekt ist: „Mit 95 % Wahrscheinlichkeit liegt dieser bereits feste Parameter in genau diesem berechneten Intervall.“

3.5 t-Konfidenzintervall für einen Mittelwert

$$KI_{\mu} = \bar{x} \pm t_{1-\alpha/2;\,n-1}\frac{s}{\sqrt{n}}$$

- **Größen:** $\bar{x}$ = Stichprobenmittelwert; s = Stichprobenstandardabweichung mit $n-1$; $t_{1-\alpha/2;\,n-1}$ = in der Aufgabe angegebener kritischer Wert.
- **Voraussetzungen:** metrische Daten, unabhängige Beobachtungen; bei kleinem n eine mit der Normalverteilung verträgliche Form ohne dominierende Ausreißer.

- **Einheit:** dieselbe Einheit wie x.
- **Warnung:** Das Intervall betrifft den Populationsmittelwert, nicht 95 % der Einzelwerte. Repräsentativität folgt nicht aus einer schmalen Intervallbreite.

3.6 Gepaarter t-Test

Zuerst je vollständigem Paar:

$$d_i = x_{i,\text{vor}} - x_{i,\text{nach}}$$

Dann:

$$\bar{d} = \frac{1}{n}\sum_{i=1}^{n} d_i, \qquad s_d = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(d_i - \bar{d})^2}$$

$$SE(\bar{d}) = \frac{s_d}{\sqrt{n}}, \qquad t = \frac{\bar{d} - 0}{s_d/\sqrt{n}}, \qquad df = n - 1$$

- **Größen:** d_i = Differenz des Paares; $\bar{d}$ = mittlere Differenz; s_d = Stichprobenstandardabweichung der Differenzen; n = Zahl vollständiger Paare.
- **Voraussetzungen:** echte Zuordnung vor/nach je Einheit; unabhängige Paare; metrische Differenzen; bei kleinem n eine mit der Normalverteilung verträgliche Form dieser Differenzen, ohne dominierende Ausreißer.
- **Einheit:** $d_i, \bar{d}, s_d, SE(\bar{d})$ in der Einheit der Messgröße; t und df einheitenlos.
- **Warnung:** Nicht die Standardabweichungen zweier Runden voneinander abziehen. Unvollständige Fälle sind keine Paare. Die Richtung von d_i vorab festlegen und beim Vorzeichen interpretieren.

Im ARSnova-Lehrfall gilt für absolute Schätzfehler:

$$d_i = |Fehler_{i,R1}| - |Fehler_{i,R2}|$$

- **Größen:** $Fehler_{i,R1}, Fehler_{i,R2}$ = Abstände der beiden Schätzungen derselben Person vom vorab festgelegten Referenzwert.
- **Voraussetzungen:** vollständige Paare und in beiden Runden dieselbe Referenz sowie dieselbe Maßeinheit.
- **Einheit:** dieselbe Einheit wie die Schätzwerte.
- **Warnung:** Durch die festgelegte Reihenfolge bedeutet ein positiver Wert eine Verringerung des absoluten Fehlers; das Vorzeichen nicht umgekehrt deuten.

Zweiseitige Hypothesen und Entscheidung:

$$H_0 : \mu_d = 0, \qquad H_1 : \mu_d \neq 0$$

$$p \leq \alpha \Rightarrow H_0 \text{ verwerfen}; \qquad p > \alpha \Rightarrow H_0 \text{ nicht verwerfen}$$

- **Größen:** μ_d = Populationsmittel der Differenzen; p = unter H_0 berechnete Wahrscheinlichkeit für mindestens so extreme Daten; α = vorab gesetztes Signifikanzniveau.
- **Voraussetzungen:** Testart und Richtung wurden vor Ergebnisbetrachtung festgelegt.
- **Einheit:** p, α einheitenlos.
- **Warnung:** p ist nicht die Wahrscheinlichkeit, dass H_0 wahr ist. „Nicht verwerfen“ beweist H_0 nicht. Signifikanz ist weder Effektgröße noch Kausalitätsnachweis.

---

4. Korrelation, lineare Regression und Residuen

4.1 Pearson-Korrelation

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \cdot \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

- **Größen:** x_i, y_i = gepaarte metrische Werte; $-1 \leq r \leq 1$.
- **Voraussetzungen:** gepaarte Beobachtungen, Variation in beiden Variablen; für sinnvolle Interpretation annähernd linearer Zusammenhang ohne dominierende Ausreißer.
- **Einheit:** r ist einheitenlos.
- **Warnung:** $r = 0$ schließt einen nichtlinearen Zusammenhang nicht aus. Korrelation beweist keine Kausalität und ist ausreißerempfindlich.

4.2 Steigung und Achsenabschnitt der einfachen Regression

$$b_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \qquad b_0 = \bar{y} - b_1\bar{x}$$

- **Größen:** b_1 = geschätzte Änderung von y je zusätzlicher Einheit x; b_0 = geschätztes y bei $x = 0$.
- **Voraussetzungen:** metrische gepaarte Daten und Variation in x; lineares Modell ist für den betrachteten Bereich plausibel.
- **Einheit:** b_1 in „Einheiten y je Einheit x“; b_0 in der Einheit von y.
- **Warnung:** b_0 hat keine sinnvolle Sachinterpretation, wenn $x = 0$ außerhalb des beobachteten oder sachlich möglichen Bereichs liegt.

4.3 Regressionsgerade und Vorhersage

$$\hat{y} = b_0 + b_1 x$$

- **Größen:** $\hat{y}$ = vom Modell vorhergesagter Wert für ein gegebenes x.
- **Voraussetzungen:** dieselbe lineare Modellannahme wie oben; Vorhersage möglichst innerhalb des beobachteten x-Bereichs.
- **Einheit:** dieselbe Einheit wie y.
- **Warnung:** $\hat{y}$ ist keine sichere Einzelwertprognose. Extrapolation kann unplausibel sein.

4.4 Residuum

$$e_i = y_i - \hat{y}_i$$

- **Größen:** y_i = beobachteter Wert; $\hat{y}_i$ = Vorhersage; e_i = Vorhersagefehler mit Vorzeichen.
- **Voraussetzungen:** Beobachtung und Vorhersage gehören zum selben Fall.
- **Einheit:** dieselbe Einheit wie y.
- **Warnung:** Positives Residuum bedeutet: Beobachtung liegt über der Vorhersage. Die Reihenfolge nicht vertauschen.

4.5 Bestimmtheitsmaß bei einfacher Regression mit Achsenabschnitt

$$R^2 = r^2$$

- **Größen:** R^2 = Anteil der im linearen Stichprobenmodell erklärten Variation von y.
- **Voraussetzungen:** einfache lineare Regression mit genau einem Prädiktor und Achsenabschnitt.
- **Einheit:** einheitenlos, häufig in Prozent.
- **Warnung:** Hohes R^2 beweist weder Kausalität noch gute Vorhersage auf neuen Daten.

5. Binäre Klassifikation

Tatsächliche Klasse	als positiv vorhergesagt	als negativ vorhergesagt
positiv	TP: True Positive	FN: False Negative
negativ	FP: False Positive	TN: True Negative

„Positiv“ bezeichnet die vorab festgelegte Zielklasse, nicht automatisch ein gutes Ergebnis.

5.1 Accuracy

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Größen:** Zähler = alle korrekten Klassifikationen; Nenner = alle ausgewerteten Fälle.
- **Voraussetzungen:** Jeder Fall steht genau einmal in der Matrix.
- **Einheit:** einheitenloser Anteil bzw. Prozent.
- **Warnung:** Bei stark ungleichen Klassen kann hohe Accuracy trotz schlechter Erkennung der seltenen Zielklasse entstehen.

5.2 Precision

$$Precision = \frac{TP}{TP + FP}$$

- **Größen:** Nenner = alle als positiv vorhergesagten Fälle.
- **Voraussetzungen:** $TP + FP > 0$.
- **Einheit:** einheitenloser Anteil bzw. Prozent.
- **Warnung:** Precision beantwortet „Wie viele positive Vorhersagen waren richtig?“, nicht „Wie viele tatsächliche Positive wurden gefunden?“

5.3 Recall

$$Recall = \frac{TP}{TP + FN}$$

- **Größen:** Nenner = alle tatsächlich positiven Fälle.
- **Voraussetzungen:** $TP + FN > 0$.
- **Einheit:** einheitenloser Anteil bzw. Prozent.
- **Warnung:** Recall beantwortet „Wie viele tatsächliche Positive wurden gefunden?“, berücksichtigt aber FP nicht.

5.4 F1-Score

$$F1 = \frac{2TP}{2TP + FP + FN}$$

Sind Precision und Recall definiert und ist ihre Summe positiv, gilt gleichwertig:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

- **Größen:** harmonische Zusammenfassung von Precision und Recall.
- **Voraussetzungen:** Für die Zählform gilt $2TP + FP + FN > 0$; für die harmonische Form müssen zusätzlich Precision und Recall definiert sowie $Precision + Recall > 0$ sein.

- **Einheit:** einheitenlos zwischen 0 und 1 bzw. Prozent.
- **Warnung:** $F1$ ignoriert TN und ist nur passend, wenn Precision und Recall gemeinsam wichtig sind. Klassenverteilung und Fehlkosten zusätzlich nennen.

5.5 Verbindliche Nullnenner-Konvention dieser Materialien

- Ist der Nenner einer Metrik null, wird das Ergebnis als **nicht definiert (n. d.)** berichtet.
- Es wird nicht eigenmächtig 0 oder 1 eingesetzt.
- Accuracy ist bei null ausgewerteten Fällen n. d.
- Precision ist ohne positive Vorhersage n. d.
- Recall ist ohne tatsächlich positiven Fall n. d.
- $F1$ wird über $2TP/(2TP + FP + FN)$ bestimmt. Es ist nur dann n. d., wenn $2TP + FP + FN = 0$. Ist $TP = 0$, aber $FP + FN > 0$, beträgt $F1$ gemäß dieser Konvention 0.
- Gibt eine Aufgabe ausdrücklich eine andere Softwarekonvention vor, wird diese benannt und getrennt von der mathematischen Definition berichtet.

---

6. Auswahl- und Ergebniskontrolle

Vor dem Rechnen:

1. Was ist die Beobachtungseinheit?
2. Welches Skalenniveau und welche Einheit haben die Variablen?
3. Welcher Zähler und welcher Nenner gehören zur Frage?
4. Sind Beobachtungen unabhängig oder gepaart?
5. Verlangt die Frage eine Punktschätzung, ein Konfidenzintervall oder den im Pflichtkern ausschließlich für vollständige metrische Paare vorgesehenen gepaarten t-Test?
6. Wird nur die vorliegende Wertemenge beschrieben (n) oder aus einer Stichprobe geschlossen ($n - 1$)?
7. Sind die Voraussetzungen des gewählten Verfahrens plausibel?

Nach dem Rechnen:

1. Liegt eine Wahrscheinlichkeit bzw. Metrik zwischen 0 und 1?
2. Liegen Anteilsintervallgrenzen zwischen 0 und 1?
3. Stimmen Einheit, Vorzeichen und Größenordnung?
4. Wurde Wald oder Wilson eindeutig bezeichnet?
5. Wurden ungerundete Zwischenwerte verwendet?
6. Trennt der Ergebnissatz Beschreibung, Unsicherheit, praktische Bedeutung, Generalisierung und Kausalität?